

# Organizační úvod

*Poznámka* (Organizační úvod)

Zápočet není nutný na zkoušku. Zkouška bude mít dvě části: první bude problém, který máme nějak vyřešit pomocí probraných algoritmů, druhá pak 2 otázky z teorie. Streemování nebude, budou pravděpodobně přednášky z minulého roku (asi na Teams).

## 1 Úvod

### Definice 1.1 (AI)

Umělou inteligenci máme hlavně dvou druhů, symbolickou (pracuje nad symbolicky (formálním jazykem – např. matematickou logikou) popsaným světem, řeší například plánování a reprezentaci znalostí) a výpočetní (pracuje přímo s „reálným světem“ = daty, například ML (NN, DL, k-means, stromy), evoluční algoritmy a další přírodou inspirované algoritmy).

Symbolická AI může být třeba (klasicky taková AI má počáteční stav a akci se jménem, předpokladem, přidáním efektů a ubráním efektů):

```
on(B, A)
on(table, C)
clear(A), clear(C)

pick(X)
predpoklad: clear(X), on(A, X)
+efekty: holding(X), clear(A)
-efekty: clear(X), on(A, X)
```

*Poznámka*

Dále jsme si povídali o jednoduchých základech NN.

### Definice 1.2 (Evoluční algoritmy)

Řeší nějakou optimalizaci (hledání minima/maxima). Funguje tak, že máme nějakou populaci bodů, nějakým způsobem je křížíme + mutujeme a udržujeme velikost populace odebráním horších členů (hodnocení členů se nazývá fitness).

### Definice 1.3 (Učení s učitelem, učení bez učitele, zpětnovazebné učení)

Učení s učitelem je, že máme zadaná nějaká data i s výsledky (dělí se na klasifikaci = předpověď kategorie a regresi = předpověď „spojitého“ čísla).

Učení bez učitele není, „že bych vás tu teď opustil a uče se sami“, ale že nejsou dané správné odpovědi.

Zpětnovazebné učení je, když cílem agenta je maximalizovat nějakou zpětnou vazbu z prostředí (většinou vyjadřovanou jako číslo, kladné je „odměna“, záporná „trest“).

## 2 Zpětnovazebné učení

### Definice 2.1 (Mountain Car („autíčko v dolíčku“))

Auto je v 2D údolí a nemá výkon na to, aby vyjelo nahoru přímo. Cílem je samozřejmě dostat se nahoru (pomocí akcí dopředu, dozadu, neutral). Odměna je  $-1$  za každý krok v prostředí (před dojetím do cíle).

(Existuje i spojitější verze, kde akce – reálné číslo mezi  $-1$  a  $1$  – udává zrychlení)

### Definice 2.2 (Zpětnovazebné učení)

Ve zpětnovazebném učení máme nějakého agenta, který provádí akce v prostředí a dostává informaci o stavu a odměně (ta se často dá spočítat ze stavu, ale pro jednoduchost rozlišujeme stav a odměnu). Formálně: Agent dostává stav  $s_t$  a provede akci  $a_t$ .

### Definice 2.3

Podobně jako v AIUvod máme spojitě a diskrétní a deterministické a nedeterministické prostředí.

## 2.1 Markovské rozhodovací procesy

### Definice 2.4 (Markovský rozhodovací proces)

Markovský rozhodovací proces je čtveřice  $(S, A, P, R)$ , kde  $S$  je množina stavů,  $A$  je množina akcí (občas to bývá funkce ze stavů – v každém stavu lze provést různé akce),  $P_a(s, s')$  je přechodová funkce – pravděpodobnost, že aplikací  $a \in A$  v  $s \in S$  přejde prostředí do  $s' \in S$ ,  $R_a(s, s')$  je odměna, kterou dostane agent při přechodu z  $s \in S$  do  $s' \in S$  pomocí  $a \in A$ .  $P$  splňuje markovskou podmínku, tj. nezávisí na historii, závisí opravdu jen na  $a, s, s'$ .

### Definice 2.5 (Strategie (policy))

Chování agenta popisujeme pomocí strategie  $\pi(s, a)$ , což je pro každé  $s$  pravděpodobnostní distribuce akcí.

### Definice 2.6 (Diskontovaná odměna)

Cílem je maximalizovat odměnu (přes různé volby  $\pi$ ):  $\sum_{t=0}^{\infty} \gamma^t R_{a_t}(s_t, s_{t+1})$ , kde  $a_t = \pi(s_t)$  je akce provedená agentem v kroku  $t$  a  $\gamma < 1$  je diskontní faktor, který zajišťuje, že suma konverguje, nastavuje, jak moc je důležité získat odměny co nejdříve, ...

$V^\pi(s) = E[R] = E[\sum_{t=0}^{\infty} \gamma^t r_t | s_0 = s]$ , kde  $R$  je diskontovaná odměna,  $r_t$  je odměna získaná v čase  $t$ .  $Q^\pi(s, a)$  je očekávaná odměna, kterou dostaneme, když ve stavu  $s$  uděláme

akci  $a$  a budeme pokračovat dál strategií  $\pi$ , říkáme tomu hodnota akce  $a$  ve stavu  $s$ .

Cílem agenta je tedy najít optimální strategii  $\pi^*$  takovou, že maximalizuje  $V^\pi$ . Hodnotu stavů a akcí pro optimální strategii budeme značit  $s^*$  místo  $\pi$ .

### Definice 2.7 ( $\varepsilon$ -greedy strategie)

S pravděpodobností  $1-\varepsilon$  vybere nejlepší akci (podle známých ohodnocení) a s pravděpodobností  $\varepsilon$  zvolí náhodnou akci.

### Definice 2.8 (Monte-Carlo metody)

Pro výpočet  $V^\pi(s)$  odsimulujeme  $n$ -krát budoucnost a zprůměrujeme odměny.

### Definice 2.9 (Temporal-difference metody)

TD metody upravují ohodnocení stavů  $V(s) \leftarrow V(s) - \alpha(r + \gamma V(s') - V(s))$ .

### Definice 2.10 (Q-učení)

Q-učení funguje podobně jako temporal-difference metody, jen upravují  $Q$  místo  $V$ , a to pomocí toho, že  $V(s) = \max_a Q(s, a)$ . Tradičně je  $Q$  reprezentováno jako matice, která je na začátku nulová a následně se upravuje podle:

$$Q(s_t, a_t) \leftarrow (1 - \alpha) \cdot Q(s_t, a_t) + \alpha \cdot \left( r_t + \gamma \cdot \max_a Q(s_{t+1}, a) \right).$$

*Poznámka*

Lze si všimnout, že tu není potřeba znát pravděpodobnosti.

### Definice 2.11 (SARSA)

Skoro jako Q-učení, jen místo maxima se kouká o krok dále a používá aktuální strategii agenta.

## 3 Evoluční algoritmy

### Definice 3.1 (OneMAX)

OneMAX je problém na prostoru  $\{0, 1\}^N$ , kde chceme dosáhnout nějaký (neznámý) pattern, např. samé jedničky. Fitness funkce bude počet správných prvků, např. počet jedniček.

### **Definice 3.2** (Evoluční algoritmus násvosloví)

Jeden „krok“ se jmenuje generace, jedinci použití na výrobu jiného se nazývají jeho rodiče, on se nazývá potomek.

### **Definice 3.3** (Genetický algoritmus)

Genetický algoritmus je evoluční algoritmus, který funguje na problému kódovaném jedničkami a nulami.

Máme nějakou populaci jedinců. Na nich provedeme selekci (pomocí fitness), pak křížení (nejčastěji jednobodové, tedy že od jednoho bodu prohodíme posloupnost jedinců, ale může být i uniformní, tedy že vyberu u každého bodu náhodně). Následuje mutace, kde náhodně přehodíme bity jedinců a pak začínáme od znova.

Selekce může být ruletová (pravděpodobnost výběru jedince je fitness jedince dělená součtem fitness všech, předpokladem je  $\text{fitness} \geq 0$ ).

### **Definice 3.4** (Elitismus)

Občas se při náhodné selekci nenáhodně vyberou do dalšího kroku dva nejlepší a nevyberou dva nejhorší jedinci.

Dále se probírali různé genetické operátory na jedincích složených s čísel  $0, \dots, k-1$ , na reálných číslech a diferenční evoluci.

### **Definice 3.5** (Genetické programování)

Nelze očekávat, že g. p. vygeneruje složité programy. Lze ho použít např.

### **Definice 3.6** (Lineární genetické programování)

Vezme se nějaký triviální jazyk (stylu assembleru) a jedinci jsou posloupnost instrukcí v tomto jazyce. Pak můžeme dělat mutace: přidání, odebrání, změnění instrukce, změnění parametrů, ... Jednobodové křížení pořád docela funguje.

Těžší je to s fitness. Program, který vyhodí chybu bude mít pravděpodobně fitness 0. Místo počítání času se často počítají instrukce, které se provedou.

### **Definice 3.7** (Kartézské genetické programování)

Kartézské genetické programování používá „sít“ uzlů, kde v uzlu volíme funkci a pak volíme, které výstupy jdou jako vstup do kterého uzlu (vždy jen zleva = od vstupu programu doprava = k výstupu programu).

**Definice 3.8** (Gramatická evoluce)

Reprezentuje jedince jako posloupnost voleb, za co přepsat dotyčný neterminál..

**Definice 3.9** (Stromové genetické programování)

Jedince reprezentujeme stromem.

## 4 Neuronové sítě

Přeskočeno (byl jsem na Strojovém učení v Pythonu a chodím na Deeplearning).

**Definice 4.1** (Radial basis ? (RBF))

Do neuronových sítí nemusíme dávat přímo souřadnice, ale můžeme jim dávat na vstup i třeba vzdálenosti ( $e^{-\beta\|\mathbf{x}-\mathbf{c}\|}$ , kde  $\mathbf{c}$  jsou středy,  $\beta$  parametry, jak moc klesá hodnota s poměrem) od nějakých bodů. Ty najdeme nejčastěji pomocí k-means.

Dále se probíraly konvoluční neuronové sítě.

## 5 Neuroevoluce

**Definice 5.1** (Evoluce vah v NN)

Podíváme se na neuronové sítě jako na vektory reálných čísel a použijeme genetický algoritmus.

**Definice 5.2** (Evoluce topologie v NN)

(Např. neural architecture search.)

TODO!!!

**Definice 5.3**

Dále se probíralo hluboké zpětnovazebné učení. TODO? (Prostě používáme neuronové sítě pro předpovídání  $Q$ )

## 6 TODO

### Definice 6.1 (Particle swarn optimization (PSO))

Pamatujeme si aktuální polohu  $x$ , rychlost  $v$ , lokální nejlepší místo  $p_b$ , které částice potkala, a globální (nejlepší lokální místo všech / nějakých okolních částic)  $g_b$ .

Svoji rychlost pak upravuje na základě:

$$v \leftarrow \omega v + \varphi_p r_p (p_b - x) + \varphi_b r_b (g_b - x).$$

#### *Poznámka*

Okolí částic si můžeme definovat geometricky (blízkost v aktuální situaci), nebo topologicky (blízkost definovaná přímo na jedincích, např. sousedi v mřížce, nemění se).

Topologické okolí se občas používá i v genetických algoritmech (genetické operace se používají jen na okolních jedincích).

### Definice 6.2 (Ant colony optimization)

Jedinci prohledávají graf, pokud najdou dobré řešení, tak při cestě „zpět“ zanechávají feromony, které následně následují jedinci, co je potkají. Hladina feromonů v každém místě se s časem zmenšuje.

### Definice 6.3 (Artificial bee colony)

TODO?