

# Organizační úvod

## *Poznámka*

Podmínkou zápočtu je splnění 1 domácí práce a 1 písemného testu. Není potřeba docházka.

Bude moodle (přístup dají cvičící). Budou tam poznámky k přednášce, cvičebnice a bude se tam odevzdávat domácí práce.

Je dobré umět míru.

## 1 Úvod

### *Poznámka*

Pravděpodobnost popisuje modely popisující náhodné jevy.

Statistika se pak snaží popsat reálné věci za pomoci těchto modelů.

### *Poznámka (Historie)*

Klasická pravděpodobnost navazuje na dílo Kolmogorova, který popisoval axiomatickou pravděpodobnost.

## 2 Pravděpodobnostní prostor

### **Definice 2.1** (Pravděpodobnostní prostor, pravděpodobnost)

Pravděpodobnostní prostor je trojice  $(\Omega, \mathcal{A}, P)$ , kde  $\Omega$  je neprázdná množina,  $\mathcal{A}$  je  $\sigma$ -algebra a  $P$  je pravděpodobnost.

Pravděpodobnost  $P$  je množinová funkce  $\mathcal{A} \rightarrow [0, 1]$  splňující:

- $P(A) \geq 0 \ \forall A \in \mathcal{A}$ , (nezápornost)
- $P(\Omega) = 1$ , (normovanost)
- jsou-li  $A_i \in \mathcal{A}$  po dvou disjunktní, pak  $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$ . ( $\sigma$ -aditivita)

┌ *Poznámka* (Interpretace)

$\Omega$  se často nazývá stavový prostor a obsahuje všechny „realizace náhody“ neboli elementární jevy, tj. všechny možnosti, o kterých uvažují.

$\mathcal{A}$  je  $\sigma$ -algebra náhodných jevů.  $P$  pak obsahuje veškerou informaci o té dané náhodné situaci.

└ Pokud nastal  $\omega \in A \in \mathcal{A}$  ( $\omega \in \Omega$ ), pak nastal jev  $A$ .

**Definice 2.2** (Klasický pravděpodobnostní prostor, diskrétní pravděpodobnostní prostor, spojitý pravděpodobnostní prostor, indikátor)

$\Omega$  konečná,  $\mathcal{A} = 2^\Omega$ ,  $P(\{a\}) = \frac{1}{n} \forall a \in \Omega$  je klasický pravděpodobnostní prostor.

$\Omega$  spočetná (včetně konečná),  $\mathcal{A} = 2^\Omega$ ,  $p : \Omega \rightarrow [0, 1]$  je taková, že  $p(\omega) \geq 0 \forall \omega \in \Omega$  a  $\sum_{\omega \in \Omega} p(\omega) = 1$ . Položíme  $P(A) = \sum_{\omega \in A} p(\omega) \forall A \in \mathcal{A}$  nazýváme diskrétní pravděpodobnostní prostor.

$\Omega = \mathbb{R}$ ,  $\mathcal{A} = \mathcal{B}(\mathbb{R})$  (resp.  $\mathcal{B}_0(\mathbb{R})$ ) a  $g : \mathbb{R} \rightarrow [0, \infty)$  měřitelná, že  $\int_{\mathbb{R}} g(x) dx = 1$ , pak definujeme  $P(B) = \int_B g(x) dx$ ,  $b \in \mathcal{B}(\mathbb{R}) = \mathcal{A}$  je spojitý pravděpodobnostní prostor. Speciálním případem  $g(x) = 1_{[0,1]}(x)$  je pak tzv. indikátor.

**Definice 2.3** (Jev jistý, jev nemožný, podjev, zároveň, alespoň jeden, jev opačný, neslučitelné jevy)

$\Omega$  je jev jistý,  $\emptyset$  je jev nemožný,  $A \subset B$  znamená „ $A$  je podjev  $B$ “,  $A \cap B$  znamená „nastal  $A$  a zároveň  $B$ “,  $A \cup B$  znamená „nastal  $A$  nebo  $B$ “,  $A^C$  je jev opačný,  $A \cap B = \emptyset$  jsou neslučitelné jevy.

**Věta 2.1**

*Budte  $(\Omega, \mathcal{A}, P)$  pravděpodobnostní prostor a  $A, B, A_i \in \mathcal{A}$  ( $i \in \mathbb{N}$ ) náhodné jevy. Pak platí:*

- $P(\emptyset) = 0$ ;
- $P$  je konečně aditivní;
- $P(A^C) = 1 - P(A)$ ;
- $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ ;
- $A \subset B \implies P(A) \leq P(B)$ ; (monotonie)
- $A_1 \subseteq A_2 \subseteq \dots \implies P(\bigcup_{i=1}^{\infty} A_i) = \lim_{n \rightarrow \infty} P(A_i)$ ; (spojitost)
- $A_1 \supseteq A_2 \supseteq \dots \implies P(\bigcap_{i=1}^{\infty} A_i) = \lim_{n \rightarrow \infty} P(A_i)$ ; (spojitost)
- $A_1 \supseteq A_2 \supseteq \dots \wedge \bigcap_{i=1}^{\infty} A_i = \emptyset \implies \lim_{n \rightarrow \infty} P(A_i) = 0$ ; (spojitost v nule)
- $B \subset A \implies P(A \setminus B) = P(A) - P(B)$ .

┌ *Důkaz*

Vše z míry. Pravděpodobnost je konečná, předposlední bod vyplývá z předchozího. □

*Poznámka*

28. února bude v 17:20 náhradní přednáška za poslední přednášku.

### Věta 2.2 (Princip inkluze a exkluze)

Buď  $(\Omega, \mathcal{A}, P)$  pravděpodobnostní prostor. Pak pro každé  $n \in \mathbb{N}$  a každá  $A_i \in \mathcal{A}$ ,  $i \in \mathbb{N}$ , platí:

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i) - \sum_{1 \leq i < j \leq n} P(A_i \cap A_j) + \dots + (-1)^{n-1} P\left(\bigcap_{i=1}^n A_i\right).$$

┌ *Důkaz*

Nebude, v podstatě byl v diskřetce. □

## 3 Podmíněná pravděpodobnost

### Definice 3.1 (Podmíněná pravděpodobnost)

Buďte  $A, B \in \mathcal{A}$  takové, že  $P(B) > 0$ . Definujeme  $P(A|B) = \frac{P(A \cap B)}{P(B)}$  a nazýváme ji podmíněnou pravděpodobností jevu  $A$  za podmínky (jevu)  $B$ .

### Věta 3.1

Buď  $B \in \mathcal{A}$  takové, že  $P(B) > 0$ . Pak zobrazení  $P(\cdot|B) : \mathcal{A} \rightarrow [0, 1]$  splňuje definici pravděpodobnosti.

┌ *Důkaz*

Ověříme po bodech: zřejmě  $P(A|B) \geq 0 \forall A \in \mathcal{A}$ ,  $P(\Omega|B) = \frac{P(\Omega \cap B)}{P(B)} = \frac{P(B)}{P(B)} = 1$  a  $\sigma$ -aditivita plyne ze  $\sigma$ -aditivity  $P(\cdot \cap B)$  a deMorganových pravidel ( $B \cap \bigcup_{i=1}^{\infty} A_i = \bigcup_{i=1}^{\infty} A_i \cap B$ ),  $P(B)^{-1}$  se prostě z obou stran vytkne. □

*Pozor*

Podmíněná pravděpodobnost nám neříká nic o příčinné souvislosti.

*Pozorování* (O podmíněné pravděpodobnosti)

Buďte  $A, B, C \in \mathcal{A}$  a pravděpodobnost „správných“ jevů nenulová. Pak:

- $P(A \cup B|C) = P(A|C) + P(B|C) - P(A \cap B|C)$ ,

- $B \subset A \implies P(A|B) = 1$ ,
- $A \cap B = \emptyset \implies P(A|B) = 0$ ,
- $P(A|\Omega) = P(A)$ ,
- pokud  $P(\{\omega\}) > 0$ , pak  $\forall A \in \mathcal{A}$  platí  $P(A|\{\omega\}) = \delta_\omega(A)$ .

┌

*Důkaz*

└

Triviální (buď z definice, nebo z toho, že je to pravděpodobnost). □

*Pozor (Neplatí!)*

$P(A|B \cup C) = P(A|B) + P(A|C)$ , ani v případě, že  $A \cap B = \emptyset$ .

### Věta 3.2 (O násobení pravděpodobností)

*Budte  $A_1, A_2, \dots, A_n \in \mathcal{A}$  takové, že  $P(A_1 \cap A_2 \cap \dots \cap A_{n-1}) > 0$ . Pak*

$$P(A_1 \cap A_2 \cap \dots \cap A_n) = P(A_n | A_1 \cap \dots \cap A_{n-1}) \cdot P(A_{n-1} | A_1 \cap A_2 \cap \dots \cap A_{n-2}) \cdot \dots \cdot P(A_2 | A_1) \cdot P(A_1).$$

┌

*Důkaz*

Z  $P(A_1 \cap \dots \cap A_{n-1}) > 0$  plyne, že  $P(A_1 \cap \dots \cap A_k) > 0$  pro  $k \in [n-1]$ , pomocí monotonie pravděpodobnosti. Tedy výraz je dobře definován.

Dokážeme indukcí: Pro  $n = 2$  platí  $P(A_1 \cap A_2) = P(A_2 | A_1) \cdot P(A_1)$  z definice. Z  $n - 1$  na  $n$ : ( $B := A_1 \cap \dots \cap A_{n-1}$ )

$$\begin{aligned} P(A_1 \cap A_2 \cap \dots \cap A_n) &= P(B \cap A_n) \stackrel{\text{def}}{=} P(A|B) \cdot P(B) \stackrel{\text{IP}}{=} \\ &= P(A_n | A_1 \cap \dots \cap A_{n-1}) \cdot P(A_{n-1} | A_1 \cap A_2 \cap \dots \cap A_{n-2}) \cdot \dots \cdot P(A_2 | A_1) \cdot P(A_1). \end{aligned}$$

└

□

### Věta 3.3 (O celkové pravděpodobnosti)

*Budte  $A, B_1, B_2, \dots$  náhodné jevy takové, že  $P(\bigcup_n B_n) = 1$  a  $B_i \cap B_j = \emptyset \forall i \neq j$  a  $P(B_i) > 0 \forall i$ . Potom  $P(A) = \sum_n P(A|B_n) \cdot P(B_n)$ .*

┌ *Důkaz*

Víme  $P((\bigcup_n B_n)^c) = 0$ , a tedy  $P(A) = P(A \cap \bigcup_n B_n) + P(A \cap (\bigcup_n B_n)^c) = P(A \cap \bigcup_n B_n)$ , protože  $P$  je konečně-aditivní a platí monotonie. Dle de Morganových pravidel (a toho, že průnik s další množinou zachovává disjunktnost):

$$P(A) = P\left(\bigcup_n (A \cap B_n)\right) = \sum_n P(A \cap B_n) = \sum_n P(A|B_n) \cdot P(B_n).$$

└

□

### Věta 3.4 (Bayesova)

*Za předpokladů věty o celkové pravděpodobnosti a  $P(A) > 0$ , platí  $P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_n P(A|B_n)P(B_n)}$ .*

┌ *Důkaz*

Snadný z definice podmíněné pravděpodobnosti a věty o celkové pravděpodobnosti. □

*Příklad (Pólyovo urnové schéma)*

Máme v urně  $n$  koulí  $k$  různých barev. Náhodně taháme z urny. Po vytažení koule do urny vytaženou kouli vrátíme a s ní i  $\Delta$  (pevný parametr) koulí stejné barvy.

Podle volby  $\Delta$  máme 2 základní schémata:  $\Delta = -1$  (tahání bez vracení) a  $\Delta = 0$  (tahání s vracením).

### Definice 3.2 (Nezávislé jevy)

Náhodné jevy  $A$  a  $B$  jsou nezávislé, pokud platí  $P(A \cap B) = P(A) \cdot P(B)$ .

*Pozor*

Zase to nemá nic do činění s kauzalitou.

### Věta 3.5

*Jsou-li dva jevy  $A$  a  $B$  nezávislé, pak jsou i jevy  $A$  a  $B^c$  nezávislé.*

*Je-li navíc  $P(B) > 0$ , pak  $P(A|B) = P(A)$ .*

┌  
Důkaz

$$P(A \cap B^c) = P(A) - P(A \cap B) = P(A) - P(A) \cdot P(B) = P(A) \cdot (1 - P(B)) = P(A) \cdot P(B).$$

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A) \cdot P(B)}{P(B)} = P(A).$$

└

□

### Definice 3.3 (Vzájemná nezávislost)

Buď  $\{A_\lambda\}_{\lambda \in \Lambda}$  systém náhodných jevů. Pak říkáme, že tyto jevy jsou (vzájemně) nezávislé, pokud pro každou konečnou množinu  $I \subset \Lambda$  (dále  $I \in \mathcal{F}(\Lambda)$ ) platí  $P(\bigcap_{i \in I} A_i) = \prod_{i \in I} P(A_i)$ .

### Věta 3.6

Buď  $C = \{B_1, \dots, B_k\}$ ,  $k \in \mathbb{N}$ , systém nezávislých jevů. Nahradíme-li libovolnou podmnožinu těchto jevů jejich doplňky, dostaneme opět systém nezávislých jevů

┌  
Důkaz

Indukcí podle velikosti nahrazované množiny. (Použije se předchozí věta.)

└

□

### Věta 3.7

Jsou-li jevy  $A_1, \dots, A_n, B_1, \dots, B_m$  vzájemně nezávislé a  $P(B_1 \cap \dots \cap B_m) > 0$ , pak

$$P(A_1 \cap \dots \cap A_n | B_1 \cap \dots \cap B_m) = P(A_1 \cap \dots \cap A_n) = P(A_1) \cdot \dots \cdot P(A_n).$$

┌  
Důkaz

Snadný.

└

□

## 4 Náhodné veličiny

### Definice 4.1 (Náhodný element)

Buďte  $(\Omega, \mathcal{A})$  a  $(\Omega', \mathcal{A}')$  stavové prostory. Pak každé měřitelné zobrazení  $X : \Omega \rightarrow \Omega'$  nazveme náhodný element z  $\Omega'$ .

### Definice 4.2 (Náhodná veličina)

Měřitelné zobrazení  $X : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  nazveme (reálnou) náhodnou veličinou.

**Definice 4.3** (Značení)

Místo  $\{\omega \in \Omega \mid X(\omega) \leq a\}$  píšeme  $\{X \leq a\}$ , místo  $P(\{X \leq a\})$  píšeme  $P(X \leq a)$ .

**Definice 4.4**

Buď  $X$  náhodná veličina.  $X^{-1}(\mathcal{B}(\mathbb{R}))$  značíme  $\sigma(X)$  a nazýváme  $\sigma$ -algebrou náhodných jevů generovaných náhodnou veličinou  $X$  ( $\sigma$ -algebra indukovaná  $X$ ).

**Definice 4.5** (Rozdělení náhodné veličiny)

Rozdělení náhodné veličiny  $X : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B})$  rozumíme indukovanou pravděpodobnostní mírou  $P_X$  na  $(\mathbb{R}, \mathcal{B})$  definovanou jako

$$P_X(B) = P(\{\omega \in \Omega \mid X(\omega) \in B\}) = P(X^{-1}(B)), \quad B \in \mathcal{B}.$$

*Poznámka* (A důkaz, že je to pravděpodobnostní míra)

$P_X$  je obraz míry  $P$  v zobrazení  $X$ .

**Věta 4.1** (O přenosu integrace pro  $P_X$ )

Buď  $X$  náhodná veličina a buď  $h$  měřitelná funkce  $(\mathbb{R}, \mathcal{B}) \rightarrow (\mathbb{R}, \mathcal{B})$ . Pak platí

$$\int_{\Omega} h(X(\omega)) dP(\omega) = \int_{\mathbb{R}} h(x) dP_X(x),$$

pokud existuje alespoň jedna strana.

*Důkaz*

Speciální případ věty o obrazu míry z TMI1.

□

**Definice 4.6** (Hustota náhodné veličiny)

Buď  $X$  náhodná veličina,  $P_X$  její rozdělení a  $\mu$   $\sigma$ -konečná míra na  $(\mathbb{R}, \mathcal{B})$  taková, že  $P_X \ll \mu$ . Potom  $f(x) = \frac{dP_X}{d\mu}(x)$  se nazývá hustota náhodné veličiny  $X$  vzhledem k míře  $\mu$ .

*Poznámka*

$f(x)$  je určena jednoznačně  $\mu$ -skoro všude. Pokud pro  $g : (\mathbb{R}, \mathcal{B}) \rightarrow (\mathbb{R}, \mathcal{B})$  měřitelnou platí

$$\int_{\mathbb{R}} |g(x)| dP_X(x) < \infty \quad (\forall g(x) \geq 0 \forall x),$$

pak  $\int_{\mathbb{R}} g(x) dP_X(x) = \int_{\mathbb{R}} g(x) f(x) d\mu(x)$ .

### Věta 4.2

Buď  $X$  náhodná veličina, pak platí následující rovnosti:

$$\begin{aligned} P(X \in B) &:= P(\{\omega \in \Omega | X(\omega) \in B\}) = \int_{\Omega} 1_B(X(\omega)) dP(\omega) = \int_{\mathbb{R}} 1_B(x) dP_X(x) = \int_B dP_X(x) = P_X(B) = \\ &= \int_{\mathbb{R}} 1_B(x) dP_X(x) = \int_{\mathbb{R}} 1_B(x) f(x) d\mu(x) = \int_B f(x) d\mu(x). \end{aligned}$$

┌ Důkaz

└ Je to jen sesypání faktů, které už známe. □

### Definice 4.7 (Distribuční funkce)

Mějme náhodnou veličinu  $X : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B})$ . Funkci  $F_X : \mathbb{R} \rightarrow [0, 1]$  definovanou jako  $F_X(x) = P(X \leq x)$  nazveme distribuční funkce náhodné veličiny  $X$ .

┌ Poznámka

Definice se shoduje s distribuční funkcí z TMI1. (A tedy platí věta o vlastnostech distribuční funkce, s tím, že dokonce  $\lim_{x \rightarrow +\infty} F_X(x) = 1$ .)

### Věta 4.3

Buď  $F : \mathbb{R} \rightarrow \mathbb{R}$  splňující vlastnosti distribuční funkce a  $\lim_{x \rightarrow +\infty} F(x) = 1$ . Pak existuje pravděpodobnostní prostor  $(\Omega, \mathcal{A}, P)$  a náhodná veličina  $X : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B})$  taková, že  $F_X = F$ .

┌ Důkaz

Z TMI1 víme, že existuje Lebesgueova-Stieltjesova míra  $\mu$ , jejíž distribuční funkce je  $F$ . Tj.  $\mu((-\infty, a]) = F(a)$ . Teď chybí jen dodefinovat  $(\Omega, \mathcal{A}, P)$  a  $X$ . Položíme  $(\Omega, \mathcal{A}, P) = (\mathbb{R}, \mathcal{B}, \mu)$  a  $X = \text{id}_{\mathbb{R}}$ . □

### Definice 4.8 (Názvosloví: diskrétní náhodná veličina, absolutně spojitá veličina)

Mějme diskrétní náhodnou veličinu  $P_X \equiv \mu_d$ , tj. existuje nejvýše spočetná  $\{x_i\}_{i \in I} \subset \mathbb{R}$  a  $\{p_i\}_{i \in I} \subset (0, 1]$  takových, že  $\sum_{i \in I} p_i = 1$  a platí  $P_X = \sum_{i \in I} p_i \delta_{x_i}$ .

Potom nutně  $F_X(x) = \sum_{i \in I} p_i 1_{[x, \infty)}(x)$  a také platí, že  $P_X \ll \nu$ , kde  $\nu$  je čítací míra na  $\{x_i\}_{i \in I}$ .

(Absolutně) spojitá náhodná veličina je taková, že  $P_X = \mu_a \ll \lambda$ , takže  $P_X(B) \int_B f(x) d\mu$ .

### Definice 4.9 (Kvantilová funkce)

Buď  $F_X$  distribuční funkce náhodné veličiny  $X$ . Funkce  $F_X^{-1}(u) = \inf \{x | F_X(x) \geq u\}$ ,  $u \in (0, 1)$  se nazývá kvantilová funkce náhodné veličiny  $X$ .



┌ *Poznámka*

Bude potřeba později. Teď jen: Je neklesající a zleva spojitá. Lze z ní jednoznačně odvodit  $F_X$ .

*Pozor*

Kvantilová funkce obecně není inverzní funkcí k  $F_X$ , protože inverzní funkce nemusí existovat. Ale pro  $F_X$  rostoucí a spojitou je  $F_X^{-1}$  inverzní funkcí k  $F_X$ .

## 4.1 Střední hodnota, rozptyl a momenty náhodné veličiny

### Definice 4.10 (Střední hodnota)

Střední hodnota náhodné veličiny  $X$  je číslo  $\mathbb{E}X$  dané výrazem  $\mathbb{E}X = \int_{\Omega} X(\omega) dP(\omega)$ , pokud má integrál smysl.

### Definice 4.11 (Medián)

Medián rozdělení náhodné veličiny  $X$  je číslo  $q_{\frac{1}{2}}$  splňující  $P(X \leq q_{\frac{1}{2}}) \geq \frac{1}{2}$  a  $P(X \geq q_{\frac{1}{2}}) \geq \frac{1}{2}$ .

### Věta 4.4

Bud'  $X$  náhodná veličina a  $g : \mathbb{R} \rightarrow \mathbb{R}$  měřitelná funkce. Pak  $g(X)$  je také náhodná veličina a  $\mathbb{E}g(X) = \int_{\mathbb{R}} g(x) dP_X(x) = \int_{\mathbb{R}} g(x) dF_X(x)$ , pokud alespoň jeden z výrazů existuje.

┌ *Důkaz*

Složení 2 měřitelných funkcí je měřitelné, tj.  $g(X)$  je opravdu náhodná veličina.

$$\mathbb{E}g(X) = \int_{\Omega} g(X(\omega)) dP(\omega) = \int_{\mathbb{R}} g(x) dP_X(x).$$

┌ Druhá rovnost plyne ze vztahu mezi  $P_X$  a její distribuční funkcí. □

### Věta 4.5 (Základní vlastnosti $\mathbb{E}X$ )

Bud'  $X, Y$  náhodné veličiny na stejném pravděpodobnostním prostoru  $(\Omega, \mathcal{A}, P)$ . Pak platí

$$\mathbb{E}(a + bX) = a + b\mathbb{E}X, \quad X \in L^1, a, b \in \mathbb{R},$$

$$\mathbb{E}(X + Y) = \mathbb{E}X + \mathbb{E}Y, \quad X, Y \in L^1,$$

$$P(X \geq 0) = 1 \implies \mathbb{E}X \geq 0, \quad (\text{obecněji } P(X \in [a, b]) = 1 \implies \mathbb{E}X \in [a, b]),$$

$$X \in L^1 \implies |X| \in L^1,$$

$$X \leq Y, P\text{-skoro všude} \implies \mathbb{E}X \leq \mathbb{E}Y (\text{pokud existují}).$$

┌ *Důkaz*

└ Snadný, aplikace míry. □

### **Definice 4.12** (Názvosloví: $P$ -skoro jistě)

$P$ -skoro jistě znamená  $P$ -skoro všude.

### **Definice 4.13** ( $n - t$ moment)

$n$ -tý moment náhodné veličiny  $X$  definujeme jako  $\mathbb{E}X^n$ ,  $n \in \mathbb{N}$ .

$n$ -tý absolutní moment náhodné veličiny  $X$  definujeme jako  $\mathbb{E}|X|^n$ ,  $n \in \mathbb{N}$ .

$n$ -tý centrální moment náhodné veličiny  $X$  definujeme jako  $\mathbb{E}(X - \mathbb{E}X)^n$ ,  $n \in \mathbb{N}$ , pokud  $\mathbb{E}X \in \mathbb{R}$ .

$n$ -tý absolutní centrální moment náhodné veličiny  $X$  definujeme jako  $\mathbb{E}|X - \mathbb{E}X|^n$ ,  $n \in \mathbb{N}$ , pokud  $\mathbb{E}X \in \mathbb{R}$ .

┌ *Poznámka*

└ 1-ní moment je  $\mathbb{E}X$ . První centrální moment je 0.

### **Definice 4.14** (Rozptyl)

Rozptyl náhodné veličiny  $X$  je definován jako  $\mathbb{E}(X - \mathbb{E}X)^2$ . Značí se  $\text{var } X$ .

┌ *Poznámka*

└ Rozptyl je střední čtvercová odchylka  $X$  od  $\mathbb{E}X$ .  $\text{var } X = \mathbb{E}(X - \mathbb{E}X)^2 \geq 0$ .  $\text{var } X = 0$  právě tehdy, když  $X = \mathbb{E}X$  skoro jistě.

### **Věta 4.6** (Základní vlastnosti rozptylu)

$$\text{var}(a + bX) = b^2 \text{var } X, \quad a, b \in \mathbb{R} \wedge X \in L^2.$$

┌ *Důkaz*

$$\text{var}(a+bX) = \mathbb{E}(a+bX - \mathbb{E}(a+bX))^2 = \mathbb{E}(a+bX - a - b\mathbb{E}X)^2 = \mathbb{E}(bX - b\mathbb{E}X)^2 = \mathbb{E}(b(X - \mathbb{E}X))^2 = b^2 \mathbb{E}(X - \mathbb{E}X)^2 = b^2 \text{var } X.$$

└ □

### **Věta 4.7** (Čebyševova nerovnost)

Buď  $X \in L^1$  náhodná veličina. Pak  $P(|X - \mathbb{E}X| \geq a) \leq \frac{\text{var } X}{a^2}$ ,  $\forall a > 0$ .

┌ Důkaz

└ Viz TMI1. □

### Definice 4.15 (Markovova nerovnost)

Buď  $X \in L^n$ ,  $n \in \mathbb{N}$ , náhodná veličina. Pak  $P(|X| \geq a) \leq \frac{\mathbb{E}|X|^n}{a^n}$ ,  $\forall a > 0$ .

┌ Důkaz

└ Obdobně Čebyševově větě. □

### Věta 4.8 (Nerovnost mezi $L^p$ normami na pravděpodobnostních prostorech)

Buď  $X$  náhodná veličina,  $0 < \alpha < \beta \in \mathbb{R}$  a  $\mathbb{E}|X|^\beta < \infty$ . Pak platí  $\sqrt[\alpha]{\mathbb{E}|X|^\alpha} \leq \sqrt[\beta]{\mathbb{E}|X|^\beta}$ , a speciálně tedy platí  $\mathbb{E}|X| \leq \sqrt{\mathbb{E}X^2}$ .

┌ Důkaz

$$\mathbb{E}|X|^\alpha = \int_{\mathbb{R}} |x|^\alpha dP_X(x) = \int_{\mathbb{R}} |x|^\alpha \cdot 1 dP_X(x) \stackrel{\text{Hölder na } p = \frac{\beta}{\alpha}}{\leq} \left( \int_{\mathbb{R}} |x|^\beta dP_X(x) \right)^{\frac{\alpha}{\beta}} \cdot \left( \int_{\mathbb{R}} 1^\beta dP_X(x) \right)^{\frac{1}{\beta}} = \dots \cdot 1.$$

(Integrál napravo je konečný z předpokladů této věty, tedy splňujeme předpoklady Höldera.) Odmocněním  $\alpha$  dostáváme přesně chtěnou nerovnost. □

### Například (Absolutně spojitá rozdělení)

Rovnoměrné rozdělení intervalu  $[a, b]$ ,  $a < b \in \mathbb{R}$  značíme  $R([a, b])$  a jeho hustota je až na konstantu Lebesgueova míra:  $f_X(x) = \frac{1}{b-a} 1_{(a,b)}(x)$ .

$$F_X(t) = \begin{cases} 0, & t \leq a, \\ \frac{x-a}{b-a}, & t \in [a, b], \\ 1, & t \geq b. \end{cases} \quad \mathbb{E}X = \int_a^b x \cdot \frac{1}{b-a} dx = \frac{b+a}{2}, \text{ var } X = \mathbb{E}X^2 - (\mathbb{E}X)^2 = \frac{(b-a)^2}{12}.$$

Exponenciální rozdělení s parametrem  $\lambda > 0$  značíme  $Exp(\lambda)$ .  $P(X > t) = e^{-t\lambda}$ ,  $t > 0$ .  $F_X(t) = P(X \leq t) = 1 - e^{-\lambda t}$  pro  $t \geq 0$  a 0 pro  $t \leq 0$ .  $f_X(x) = \lambda e^{-\lambda x}$ ,  $x \geq 0$  a  $f_X(x) = 0$  jinak.  $\mathbb{E}X = \frac{1}{\lambda}$ ,  $\text{var } X = \frac{1}{\lambda^2}$ .

┌ Poznámka

└ Exponenciální rozdělení má vlastnost ztráty paměti, tedy že  $P(X > s + t | X > s) = P(X > t)$ ,  $s, t > 0$ .

Normální (Gaussovo) rozdělení: Normované  $N(0, 1)$  je  $f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$ ,  $x \in \mathbb{R}$ .  $F_X(t) = \int_{-\infty}^t \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx$ . Tyto  $F_X$  a  $f_X$  se často značí  $\Phi$  a  $\varphi$ .  $\mathbb{E}X = 0$  ( $x \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$  je lichá funkce),  $\text{var } X = \mathbb{E}(X - \mathbb{E}X)^2 = \mathbb{E}X^2 = 1$ .  $\mathbb{E}X^{2k+1} = 0$ .

Obecné  $N(\mu, \sigma^2)$ ,  $\mu \in \mathbb{R}$ ,  $\sigma^2 > 0$  má  $f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ ,  $x \in \mathbb{R}$ .

### Tvrzení 4.9

Bud'  $X$  nezáporná (tj.  $P(X \geq 0) = 1$ ) absolutně spojitá náhodná veličina, která splňuje  $P(X > s+t | X > s) = P(X > t)$ ,  $\forall s, t > 0$ , pak  $X \sim \text{Exp}$ .

┌ Důkaz

└ Dělat nebudeme. □

### Věta 4.10

$X \sim N(0, 1)$  a  $Y := \sigma X + \mu$ , pro  $\sigma > 0$ ,  $\mu \in \mathbb{R}$ . Pak  $Y \sim N(\mu, \sigma^2)$ .

┌ Důkaz

└ TODO!!! □

Důsledek

$$F_Y(t) = P(Y \leq t) = P(\sigma Z + \mu \leq t) = P\left(Z \leq \frac{t - \mu}{\sigma}\right) = \Phi\left(\frac{t - \mu}{\sigma}\right).$$

Důsledek

$$\mathbb{E}Y = \mathbb{E}(\sigma Z + \mu) = \mu + \sigma \mathbb{E}Z = \mu + 0 = \mu.$$

$$\text{var } Y = \text{var}(\sigma Z + \mu) = \sigma^2 \cdot \text{var } Z = \sigma^2.$$

### Věta 4.11 (Rozdělení funkce náhodné veličiny)

Bud'  $X$  náhodná veličina s distribuční funkcí  $F_X$ ,  $g : \mathbb{R} \rightarrow \mathbb{R}$  měřitelná funkce. Pak  $Y = g(X)$  je náhodná veličina s distribuční funkcí  $F_Y(y) = \int_{\{x|g(x) \leq y\}} dF_X(x)$ .

┌ Důkaz

$$F_Y(y) = P(Y \leq y) = P(g(X) \leq y) = P_X(\{x|g(x) \leq y\}) = \int_{\{x|g(x) \leq y\}} dF_X(x).$$

└ □